

Consignes pour le projet d'économétrie appliquée

Préambule : Vous travaillerez tous sur des bases de données qui diffèrent :

- par les variables à expliquer
 - par l'échantillon utilisé
- vous pourrez avoir des résultats différents d'un groupe à l'autre !

Etape 1: Remplissez le document excel pour choisir votre sujet en suivant le lien :

https://docs.google.com/spreadsheets/d/17gw9nmq58eeMld_nq3NFAPv8H8ZIJ_lpvbblsKpW874/edit?usp=sharing

→ Pour le 06/02

Etape 2: Je vous envoie la base de données et le dictionnaire de codes associé

Etape 3: Réalisation du projet

- Le projet est à réaliser sous STATA (lien pour le téléchargement sur agorassas)
- **Projet intermédiaire à rendre pour le 22/03 : PARTIE 1 + PARTIE 2**
- **Projet final (incluant les corrections de la première partie) à rendre pour le 26/04**
 - Rendu : autour de 20 pages (avec en plus, éventuellement, des annexes)
 - à envoyer à : anne-laure.samson@assas-universite.fr
 - le fichier (pdf ou word) doit OBLIGATOIREMENT être nommé : nom1_nom2.docx ou nom1_nom2.pdf

INTRODUCTION :

→ Présentez brièvement le sujet, les 2 variables expliquées que vous étudiez, les questions auxquelles le projet souhaite répondre.

→ Dans le modèle 1 : quelle sera votre variable d'intérêt ? vos variables de contrôle ?

Quel est l'effet attendu sur votre variable expliquée et pourquoi ? Vous pouvez utiliser des articles trouvés sur internet et votre intuition.

→ Dans le modèle 2 : quelle sera votre variable d'intérêt ? vos variables de contrôle ?

Quel est l'effet attendu sur votre variable expliquée et pourquoi ? Vous pouvez utiliser des articles trouvés sur internet et votre intuition.

Attention : Il y aura 2 modèles différents à présenter, avec 2 variables expliquées différentes.

- Les deux variables explicatives peuvent être liées : La 1^{ère} variable expliquée peut-être une variable explicative dans le second modèle et/ou la 2^{ème} variable expliquée peut-être une variable explicative dans le premier modèle.
Exemple : modèle 1 = probabilité de travailler de nuit ;

Modèle 2 = satisfaction au travail

→ la probabilité de travailler de nuit est une variable explicative de la satisfaction au travail. En revanche, la satisfaction au travail n'est sans doute pas pertinente pour expliquer la probabilité de travailler de nuit)

- Elles peuvent aussi être liées car la seconde apporte une précision sur la première.
Exemple : modèle 1 : probabilité d'appartenir à une association
Modèle 2 : fréquence de participation à cette association
Ici certaines des variables (ou toutes les variables explicatives) peuvent être les mêmes entre les 2 modèles

PARTIE 1: STATISTIQUES DESCRIPTIVES

1- description de la base de données: nombre d'observations initial, tableaux de fréquences (variables qualitatives) ou distribution (variables quantitatives) des variables que vous avez choisi de retenir pour l'analyse

→ les 2 variables expliquées

→ les variables explicatives des 2 modèles

La seule chose que vous devez commenter des tableaux de fréquences ou des distributions, c'est i) la présence de valeurs manquantes ; ii) la présence de valeurs aberrantes ; iii) la nécessité de regrouper ou non les modalités de certaines des variables qualitatives. Les commentaires seront ensuite faits au point 2) (statistiques descriptives univariées).

Suite à l'analyse de i), ii) et iii), vous devez « nettoyer » votre base, ie :

- supprimer les valeurs manquantes (selon la méthode vue en TD : si une variable explicative compte trop de valeurs manquantes, ie. plus de 5% des observations, vous pouvez soit décider de ne pas l'utiliser, soit décider de créer une modalité à part pour ces valeurs manquantes ; si il y a moins de 5% d'observations manquantes, vous pouvez supprimer ces valeurs manquantes. Attention : si c'est votre variable expliquée qui comporte des valeurs manquantes, vous ne pouvez rien faire d'autre que les supprimer)
- supprimer les valeurs atypiques des variables continues, si besoin.
- regrouper les modalités des variables catégorielles, si nécessaire (ie. si les effectifs de certaines modalités sont trop faibles – idéalement il faut que chaque modalité regroupe au moins ~10% des effectifs)

Cela vous conduit à un échantillon unique, sur lequel toute la suite de l'analyse est effectuée

2- statistiques descriptives après « nettoyage » des variables : présenter le nombre d'observation final, les tableaux de fréquence et les graphiques de vos différentes variables.

→ les 2 variables expliquées

→ les variables explicatives des 2 modèles

Commenter les principaux résultats de ces statistiques.

3- statistiques bivariées et test d'indépendance des variables :

→ effectuer tableaux croisés + test de Chi-2 d'indépendance + graphique adéquat entre la variable expliquée et la variable d'intérêt (uniquement elle), pour chacun des deux modèles.

Pensez à bien commenter les différents résultats

La séance de TD n°1 sera consacrée à un résumé de ces statistiques descriptives

PARTIE 2: PREMIER MODELE ECONOMETRIQUE : modèle LOGIT simple

Ce modèle doit être estimé sur le même échantillon final que celui qui aura été défini au point 2) de la PARTIE 1.

1- présentation théorique du modèle estimé: c'est-à-dire écriture du modèle estimé, signification de la variable latente, variables explicatives introduites

2- Résultats des estimations :

→ trouver le meilleur modèle expliquant votre variable expliquée : vous pouvez procéder comme au 1^{er} semestre : inclusion de la variable d'intérêt, puis des variables explicatives progressivement, par grands groupes, en supprimant celles qui vous semblent peu explicatives. Vous expliquerez votre démarche.

→ à partir de ce modèle, copier-coller les 3 sorties STATA montrant i) les coefficients ; ii) les odd-ratios ; iii) les effets marginaux du modèle final (inutile de présenter les 3 tableaux pour les modèles intermédiaires ; seul celui des coefficients suffit pour la phase de sélection du meilleur modèle).

3-Commentaires des résultats : commentez ces 3 tableaux.

4-Evaluer la qualité d'ajustement de votre modèle : en analysant les résultats du tableau de concordance et de la courbe ROC

PARTIE 3: SECOND MODELE ECONOMETRIQUE : modèle LOGIT ordonné ou LOGIT multinomial selon le sujet choisi

Ce modèle doit être estimé sur le même échantillon final que celui qui aura été défini au point 2) de la PARTIE 1 et que celui utilisé dans la PARTIE 2.

1- présentation théorique du modèle estimé : justification du modèle choisi (ordonné ou multinomial), écriture du modèle estimé, signification de la variable latente, variables explicatives introduites

2- Résultats des estimations :

→ trouver le meilleur modèle expliquant votre variable expliquée : vous pouvez procéder comme au 1^{er} semestre : inclusion de la variable d'intérêt, puis des variables explicatives progressivement, par grands groupes, en supprimant celles qui vous semblent peu explicatives. Vous expliquerez votre démarche.

→ à partir de ce modèle, copier-coller les 3 sorties STATA montrant i) les coefficients ; ii) les odd-ratios ; iii) les effets marginaux du modèle

- *Pour ceux d'entre vous qui estimeront des modèles **logit ordonnés**, il faut bien penser à effectuer le test "d'égalité des pentes". Toutefois, si le test conclut à l'absence d'égalité des pentes, il n'est pas nécessaire d'estimer un modèle logit multinomial en complément.*

3- Commentaires des résultats : commentez ces 3 tableaux.

CONCLUSION BREVE

BAREME INDICATIF: (/20)

- ponctualité dans le choix du sujet /1
- qualité de la présentation (lisibilité des graphiques, tableaux non coupés, syntaxe et clarté des explications,) /2
- Introduction /1
- Partie 1: statistiques descriptives /5
- Partie 2: 1er modèle économétrique : modèle LOGIT simple /5
- Partie 3: 2nd modèle économétrique: modèle LOGIT ordonné ou multinomial /5
- Conclusion /1